
Identificación automática de cuentas bot en proyectos *Open-Source*

Miguel Ángel Fernández Sánchez Máster en Data Science Tutor: Dr. José Felipe Ortega Soto

Universidad
Rey Juan Carlos

20 de abril, 2023


/motivación



/motivación



Cuentas




Organizaciones




/motivación Identidad A Mezcla estos perfiles Identidad B Añade esta Universidad organización Rey Juan Carlos Marca este perfil Nombre: autobot como bot Bot: Sí

/problema


- Commits de humanos
- Commits de bots



/problema




/propuesta



/eligiendo la comunidad a analizar





/detalles de un commit de Git



/selección de campos mediante GQM

Author data

author uuid


author name

author bot


Author data, from commit

commit name


author date




/fase de experimentos




/análisis exploratorio de datos



/dataset de entrada




/pre-procesamiento de los datos y transformación de variables




/generación de variables


Level	Weight	Heuristic terms
1	60	bot, dependency, fix, integration, merge
2	30	auto, build, commit, copy, issue, release, request, review, sync, template, tool, travis
3	10	cd, ci, code, patrol, pr, pull




/datos desequilibrados: SMOTE





/distribución de las clases mediante t-SNE





/clasificadores: evaluación







/clasificadores: Random Forest

Número de estimadores


Criterio de división

Profundidad máxima

300

Impureza Gini


4 niveles



Bots

Humanos


/clasificadores: evaluación (test)



Model name	Precision	Recall	Fβ-score
Random Forest	0.667	0.857	0.811


+ 5-fold cross-validation

/clasificadores: validación



Model name	Precision	Recall	Fβ-score
Random Forest	0.333	0.75	0.6

/clasificadores: características más relevantes



/trabajo futuro

Mejora y extensión del modelo de clasificación

Otros proyectos / Otras comunidades

Medidas de texto / Huellas digitales

Resumen del usuario / Concept Learning

Cuentas mixtas / Clasificación multiclase

Integración con SortingHat/GrimoireLab

Informe de clasificación

Sistema de recomendación

Retroalimentación con el modelo tras la respuesta del usuario

/fin

Turno de preguntas

mafesan.github.io/Memoria-TFM